

Síntese Quantitativa de Modelos Matemáticos, Estatísticos e de Inteligência Artificial para Biomarcadores, Mecanismos e Reposicionamento Terapêutico

Rossana O. Souza¹ , Wellington Francisco Rodrigues¹ , Aristóteles Goés-Neto¹ ,
Siomar de Castro Soares , Marcos A. dos Santos¹ 

¹ Programa Interunidades de Pós-Graduação em Bioinformática da UFMG, Universidade Federal de Minas Gerais, Belo Horizonte, Brasil

rossanasouza@ufmg.br

Resumo. A interface entre informática e ciências da saúde consolidou um ecossistema de modelagem capaz de transformar dados biomédicos em evidência acionável, embora ainda marcado por heterogeneidade metodológica e lacunas de validação. Este trabalho aborda esse cenário por meio de uma síntese quantitativa das aplicações de modelos matemáticos, estatísticos e de inteligência artificial (IA) em três frentes: identificação de biomarcadores, elucidação de mecanismos de doença e (re)posicionamento/desenvolvimento terapêutico. A abordagem incluiu busca semântica em repositórios acadêmicos amplos, triagem por elegibilidade (modelagem avançada, foco em saúde humana, desfechos mensuráveis, descrição metodológica e validação) e extração padronizada de métodos, focos, áreas terapêuticas e estratégias de validação, seguida de harmonização e análise de co-ocorrências. Os resultados mostram repurposing como foco predominante (26% das menções), seguido por mecanismos (16%) e biomarcadores (14%). A diversidade algorítmica é ampla: ML clássico/ensembles e deep learning dominam as aplicações, enquanto modelos lógicos/booleanos e biologia de sistemas (ODE/PDE) são centrais para estudos mecanísticos. As validações combinam cross-validation, ensaios experimentais (in vitro/in vivo) e evidência do mundo real (EHR/claims), ainda com heterogeneidade de reporte. A síntese oferece um panorama objetivo das práticas atuais e destaca oportunidades de padronização de métricas, expansão de validações externas e integração multi-ômica, contribuindo para acelerar a translação para a medicina de precisão.

Palavras-chave: inteligência artificial em saúde; biomarcadores; mecanismos de doença; reposicionamento de fármacos; síntese quantitativa.

1. Introdução

A interface entre informática e ciências da saúde consolidou um ecossistema de modelagem matemática, estatística e de IA capaz de transformar dados biomédicos em evidência acionável, integrando multi-ômicas, registros clínicos e conhecimento biomolecular [1]. Métodos que vão de regressão e *ensembles* a *deep learning* têm sido aplicados para identificar biomarcadores, elucidar mecanismos e acelerar a (re)descoberta de fármacos, com avanços em oncologia, neurodegeneração, mapeamento de vias causais e priorização de candidatos a

reposicionamento, validados computacionalmente, experimentalmente e com dados do mundo real (EHR/claims) [2, 3]. Apesar do progresso, persistem desafios: heterogeneidade de dados e métricas, escassez de validação experimental, vieses de amostragem, limitações de reprodutibilidade e dificuldades de interpretabilidade clínica [4]. Assim, este trabalho realizou uma revisão guiada por busca semântica e extração padronizada para mapear aplicações de modelos matemáticos, estatísticos e de IA voltadas à identificação de biomarcadores, elucidação de mecanismos e reposicionamento de fármaco, quantificando distribuição por foco, métodos, áreas de doença e estratégias de validação, a fim de evidenciar oportunidades e limitações com impacto potencial na qualidade de vida [5].

2. Metodologia

Foi realizada uma síntese quantitativa de aplicações de modelos matemáticos, estatísticos e de IA em saúde. A estratégia incluiu busca semântica em repositórios indexados (p.ex., Semantic Scholar, OpenAlex) focada em biomarcadores, mecanismos e reposicionamento terapêutico, seguida de triagem com critérios a priori (modelagem além de estatística descritiva, dados de saúde humana, descrição metodológica verificável e validação). Foram incluídos estudos originais, revisões sistemáticas e meta-análises.

A extração de dados seguiu protocolo padronizado com apoio de modelo de linguagem para raspar métodos, foco, área, fontes de dados, validações e achados-chave, com checagem humana amostral para consistência. A harmonização incluiu limpeza textual, padronização de abreviações, expansão de campos multivalorados, remoção de valores vazios e normalização de rótulos. Métodos foram agrupados por palavras-chave em classes (*Deep Learning*; *ML*; *Lógico*; *Bayesian*; etc), e duplicidades foram evitadas por deduplicação por par estudo-rótulo.

As análises consistiram em contagens, proporções e ocorrências (doença $\times$ foco; validação $\times$ foco), visualizadas por barras, *bubble plot* e *heatmaps*. A robustez decorreu de padronização, expansão de listas, deduplicação e clareza de que as métricas representam menções.

3. Conclusão

A síntese quantitativa (Fig. 1) indica que o reposicionamento de fármacos foi o foco predominante (26%), seguido por mecanismos de doença (16%) e biomarcadores (14%). Temas adicionais incluíram resposta a fármacos (8%), interações fármaco-fármaco e descoberta de alvos (4% cada), além de tópicos esparsos ligados à aplicabilidade e medicina de precisão. Houve ampla diversidade algorítmica: *Random Forest* foi mais frequente (7,5%), seguida por *SVM* (4,5%). Entre grupos, destacaram-se *Other/Hybrid* (43,3%), *ML* (14,9%) e *Deep Learning* (13,4%), enquanto modelagem lógica (7,5%) e biologia de sistemas (*ODE/PDE*; 6,0%) foram relevantes para mecanismos e alvos; *Bayesian* e *graph* e testes estatísticos completaram o panorama (~4,5% cada).

O painel doença $\times$ foco mostra predominância de oncologia, seguida por neurodegeneração e casos pontuais em cardiovascular, COVID-19, psoríase, osteoporose, saúde reprodutiva e transtornos de splicing. O reposicionamento concentrou-se em câncer e neurodegeneração,

enquanto mecanismos foram analisados com redes, lógica e modelos *ODE/PDE*. Quanto à validação, observou-se uso de *cross-validation* (5-, 10-, 25-fold e variantes *two-tiered*), ensaios experimentais (in vitro/in vivo, dose–response, modelos murinos) e evidência do mundo real (*EHR/claims*). Houve ainda comparações com *SOTA* e validações externas; parte dos estudos, porém, não detalhou claramente a estratégia.

No geral, o reposicionamento é a aplicação mais recorrente de modelos estatísticos em saúde, impulsionada por *ML ensembles* e *deep learning*, enquanto modelos lógicos e de sistemas seguem essenciais para elucidar mecanismos e alvos. A diversidade de métodos e validações é ampla e o corpo de evidências reforça o potencial translacional desses enfoques para identificar biomarcadores, compreender vias patológicas e priorizar reposicionamentos; próximos passos incluem padronização de métricas, validações externas ampliadas e integração multi-ômica para acelerar aplicações em medicina de precisão.




Figura 1. Aplicações de modelos computacionais em ciências da saúde: síntese quantitativa dos estudos incluídos. (A) Focos dos estudos (primário + secundário). (B) Métodos computacionais mais citados. (C) Mapa de bolhas doença × foco (Top-10). (D) Heatmap validação × foco. Notas técnicas: dados padronizados..

Disponibilidade dos dados. O material suplementar e imagens de alta resolução deste manuscrito estão disponíveis em https://github.com/rossanaoliveirasouza/bioinformatica_2035/invitations.

4. Referências

- [1] Raschka T, Sood M, Schultz B, Altay A, Ebeling C, Fröhlich H. AI reveals insights into link between CD33 and cognitive impairment in Alzheimer's Disease. *PLoS Comput Biol*. 2023;19(2):e1009894.
- [2] Aamer N, Asim MN, Dengel A. COMIC: Explainable Drug Repurposing via Contrastive Masking for Interpretable Connections. *bioRxiv*. 2025:2025.03.26.645428.
- [3] Montagud A, Béal J, Tobalina L, Traynard P, Subramanian V, Szalai B, et al. Patient-specific Boolean models of signaling networks guide personalized treatments. *bioRxiv*. 2021:2021.07.28.454126.
- [4] Maeser D, Gruener RF, Galvin R, Lee A, Koga T, Grigore FN, et al. Integration of Computational Pipeline to Streamline Efficacious Drug Nomination and Biomarker Discovery in Glioblastoma. *Cancers (Basel)*. 2024;16(9).
- [5] Voutouri C, Nikmaneshi MR, Hardin CC, Patel AB, Verma A, Khandekar MJ, et al. In silico dynamics of COVID-19 phenotypes for optimizing clinical management. *Proc Natl Acad Sci U S A*. 2021;118(3).